

DINÂMICA PRÁTICA · DESAFIO HANDS-ON

Análise de Performance Copa do Mundo 2026

Desafio hands-on a partir de um dataset real do Kaggle.

TEMPO TOTAL 2h a 2h30

STACK livre — Python (pandas/polars), SQL (DuckDB)... justifique a escolha

ENTREGÁVEL pasta com notebook/scripts + README.md com os achados

Não buscamos a “resposta certa”

O objetivo

Queremos ver como você **baixa, valida, questiona e comunica** um dado que nunca viu — não chegar a uma única resposta correta.

PARA CADA TAREFA, REGISTRE

- a** Seu raciocínio em 1 a 3 linhas.
- b** O código ou a consulta que você usou.
- c** Como você validaria o resultado obtido.

Baixe o dataset e explique sua escolha

Fonte Kaggle · **fifa_world_cup_2026_player_performance.csv** · ~17,2 MB · 75 colunas · licença MIT

CAMINHO A

Interface web

Login no Kaggle → Download do .zip → extrair o CSV para dados/.

CAMINHO B

Kaggle CLI

Token em Account › API; guarde kaggle.json fora do repo.

```
kaggle datasets download -d ../fifa-world-cup-2026... -p dados/ --unzip
```

CAMINHO C

kagglehub

Baixa por código e retorna o caminho local dos arquivos.

```
kagglehub.dataset_download("../fifa-world-cup-2026...")
```

NO README, RESPONDA

- Qual caminho usou e por quê? Como garante que o arquivo veio íntegro?
- Onde as credenciais (kaggle.json) não devem ser guardadas — e por quê?
- O que a licença MIT permite e exige ao publicar um resultado?
- O que deve e o que não deve ser versionado no Git neste projeto?

Conheça e desconfie do dado

T1.1

Tamanho e memória

Linhas, colunas e consumo de memória. Em pandas, mostre como reduziria.

T1.2

Mapa de qualidade

Por coluna: % de nulos, tipo e cardinalidade. Aponte 3 colunas suspeitas.

T1.3

As 10 categorias

Escolha uma coluna de cada grupo e diga, em 1 linha, o que mede e a unidade.

T1.4

Regras de coerência

$\text{shots_on_target} \leq \text{shots}$; minutos $\times$ jogos; goleiro $\times$ linha; idade/altura/peso plausíveis. Conte as violações.

Transforme e crie métricas com critério

T2.1**Métricas por 90 min**

goals_per90, assists_per90, key_passes_per90 — cuidado com divisão por zero.

T2.2**Top 10 artilheiros /90**

Analise criticamente e ajuste cortes para o ranking fazer sentido.

T2.3**Agregado por seleção**

Gols, assistências, média de Player Rating e soma de Distance Covered; comente o estranho.

T2.4**Goals vs xG**

over_performance = goals – xG. Quem finaliza acima e quem desperdiça? O que não é captado?

T2.5**Salvar em Parquet**

Persista o dado tratado e explique 2 vantagens do formato aqui.

Mostre — e questione o pedido

T3.1**Scatter xG × Goals**

Com a linha $y = x$ de referência; rotule apenas os principais outliers.

T3.2**Rating por posição**

Boxplot ou violino. Qual posição tem maior dispersão? Isso faz sentido?

T3.3**O “pizza 3D” do gerente**

Pediram pizza de 24 países, 3D e sombra. Você entrega? Defenda pela boa comunicação de dados.

T3.4**Bônus front-end**

Mini-página HTML self-contained (sem CDN) lendo o Parquet/JSON, ranking interativo, SVG na mão.

Responda com dado e comunique bem

T4.1

Escolha UMA pergunta

- 5 jogadores mais subvalorizados (alto impacto, baixo rating).
- Posição com maior eficiência ofensiva por minuto.
- Relação entre Distance/Sprints e Player Rating.

T4.2

Comunique em 1 frase

Uma frase que um diretor sem base técnica entenderia — seguida de um número de suporte e uma ressalva honesta sobre a limitação do dado.

T4.3

Pensamento crítico

Correlação de 0,8 entre Sprints e Rating.

Um colega quer publicar “correr mais melhora a nota”. Qual a sua objeção?

Defenda suas decisões ao vivo

- Explique uma decisão que você mudaria com mais tempo.
- Esteja pronto para ajustar um parâmetro na hora e mostrar o efeito.
- Diga o que não conseguiu validar — e o que faria para validar.

OBSERVAÇÕES

- Respeite a licença MIT — mantenha a atribuição ao autor do dataset.
- Não versione o CSV nem o kaggle.json no repositório.
- Dizer “não sei” ou “não confio neste dado”, com justificativa, é bem-visto.